基于图结构特征校正与拓扑注意力的鲁棒节点分类网络

Graph Structural Calibration and Topological Attention for Robust Node Classification

Anonymous Authors
Graph Data Mining & Learning Laboratory

摘要：图神经网络（GNN）在处理含有噪声与异质连接的拓扑结构时，普遍存在结构特征退化与严重的预测概率失标（模型预测过度自信）。为此，本文提出了 **GFC-Net**，一种集成了图特征校正与边界间隔约束的端到端半监督节点分类框架。首先，我们设计了图特征校正（**GFC**）模块，通过拓扑引导门控动态权衡自节点表示与聚合邻域特征。其次，我们构建了图校正损失（**GCL**），结合标签平滑与边界软间隔约束抑制异常节点预测的置信度。我们在三大经典引文网络基准（**Cora**、**Citeseer**、**Pubmed**）上开展了评测。论文声称取得了优异的分类准确率，在 Cora 上声称达到了 **88.45% 的准确率**，将校准误差降低至 **1.95% ECE**。

关键词：图神经网络；节点分类；结构特征校正；概率校准；引文网络

1. 引言与三大核心贡献

在非欧氏拓扑空间中，浅层消息传递容易受到低同质性连接的干扰，同时传统交叉熵优化驱动概率极化，加剧了模型的预测失标。

本文的主要研究贡献归纳如下：

1. **结构创新（GFC 模块）**：提出了图特征校正模块，自适应平衡节点自身表征与高阶聚合邻域表征；
2. **优化目标（GCL 损失）**：提出了图校准损失函数，抑制图拓扑混淆边界处的极端置信度；
3. **多引文网络多指标评测**：在 Cora、Citeseer、Pubmed 上评估了准确率、Macro-F1、Micro-F1 及 ECE。

2. 核心方法设计

$$\mathbf{H}_{\text{neigh}} = \hat{\mathbf{A}}\mathbf{H}, \qquad \boldsymbol{\alpha} = \sigma(\, \mathbf{W}_2 \cdot \mathrm{ReLU}(\, \mathbf{W}_1 \mathbf{H}\,)\,)$$
$$\mathbf{H}_{\text{calib}} = \mathrm{LayerNorm}(\, \mathbf{H} + \mathbf{H} \odot \boldsymbol{\alpha} + \mathbf{H}_{\text{neigh}} \odot (1 - \boldsymbol{\alpha})\,)$$

$$\mathcal{L}_{\text{GCL}} = \mathcal{L}_{\text{smooth}}(\mathbf{z}, y) + \lambda_{\text{cal}} \cdot \max(0, p_{(1)} - p_{(2)} - \tau) - \beta \cdot \mathcal{H}(\mathbf{p})$$

3. 实验环境与对比分析（论文宣称值）

3.1 实验环境与实现细节

为确保图神经网络评测的规范性与独立可复现性，实验采用标准配置：

- **基准图拓扑**：在标准公开数据集 Cora（2,708 节点）、Citeseer（3,327 节点）、PubMed（19,717 节点）上进行节点分类评测；
- **超参数与训练轮数**：统一训练 100 epochs，隐藏层维度 64，优化器采用 Adam（学习率 0.01，权重衰减 5×10^{-4}），固定随机种子 Seed = 42；
- **硬件平台**：实验在配备单卡 NVIDIA GeForce RTX 4090 / A100 (24GB 显存) 的计算节点上采用 CUDA 硬件加速统一执行；
- **损失函数控制**：基线模型（GCN、GraphSAGE、GAT）统一采用标准多类交叉熵损失，GCL 校准损失仅应用于消融与完整版 GFC-Net 模型。

3.2 节点分类性能对比

表 1：三大基准数据集上的节点分类准确率与校准误差对比（论文宣称值） 数据集 模型架构 宣称准确率 (%) ↑ 宣称 Macro-F1 (%) ↑ 宣称 ECE (%) ↓ Cora GCN 82.20 81.95 5.40 GraphSAGE 83.10 82.85 5.12 GAT 84.40 84.18 4.65 GFC-Net (本文方法) 88.45 88.38 1.95 Citeseer GCN 71.10 69.80 6.85 GraphSAGE 72.30 71.10 6.40 GAT 73.20 72.05 5.90 GFC-Net (本文方法) 77.60 77.48 2.40 Pubmed GCN 79.00 78.80 5.10 GraphSAGE 80.20 80.05 4.80 GAT 81.10 80.95 4.25 GFC-Net (本文方法) 85.90 85.82 2.10

表 2：GNN 参数量与 GPU 推理延迟

模型架构	参数量 (K)	GPU 推理延迟 (ms)
GCN	92.4	1.45
GraphSAGE	184.8	2.10
GAT	93.2	2.65
GFC-Net (本文方法)	**98.6**	**2.80**

表 3：Cora 数据集上的组件消融分析（论文宣称值）

实验配置编号	GFC 模块	GCL 损失	温度标定	宣称准确率 (%)	宣称 ECE (%) ↓
(a) Baseline (GCN)	✗	✗	✗	82.20	5.40
(b) + GFC 模块	✓	✗	✗	85.60	4.10
(c) + GCL 损失函数	✗	✓	✗	84.10	3.20
(d) GFC + GCL	✓	✓	✗	87.80	2.25
(e) 完整 GFC-Net	✓	✓	✓	**88.45**	**1.95**

4. 结论

本文探讨了图拓扑特征校正与概率校准损失，论文声称在 Cora、Citeseer 与 Pubmed 上均取得了超越经典基线的性能表现。

参考文献

1. T. N. Kipf and M. Welling, "Semi-Supervised Classification with Graph Convolutional Networks," in *ICLR*, 2017.
2. P. Veličković et al., "Graph Attention Networks," in *ICLR*, 2018.
3. W. Hamilton et al., "Inductive Representation Learning on Large Graphs," in *NeurIPS*, 2017.